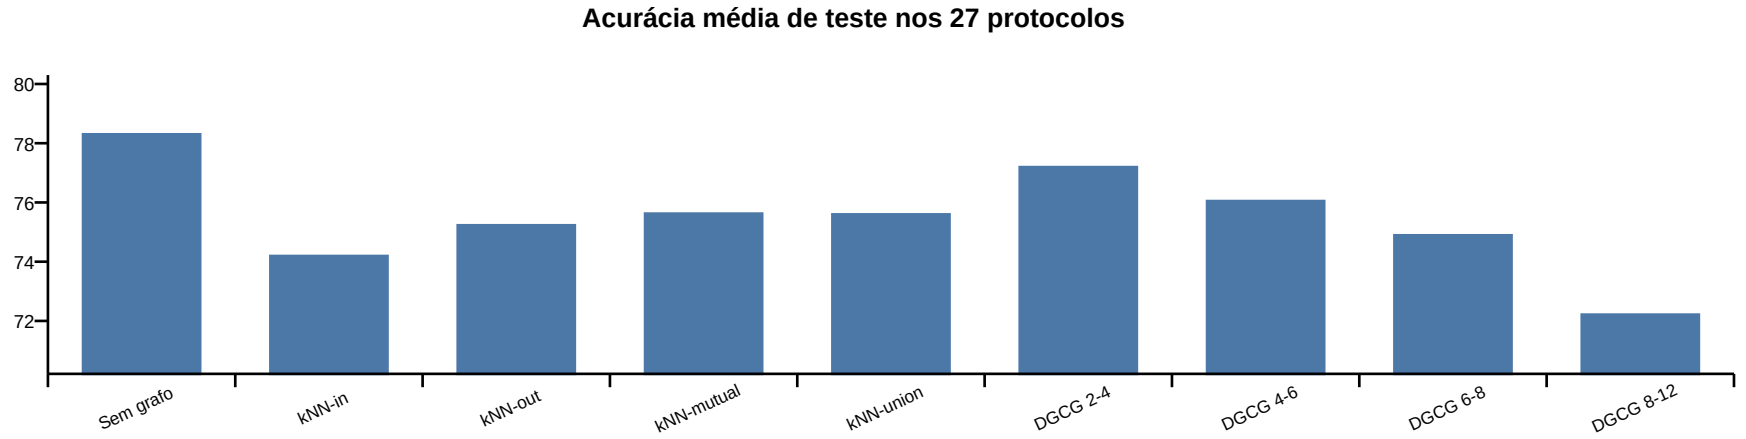
Experimentos few-shot

1. Grade principal de métodos e graus

Configuração

Bases	Protocolos	Seed	Treino	Embedding	Projeção	Execuções
10 bases Micro	27	7	2.000 episódios	512	256	2.430



Médias gerais

Método	Validação (%)	Teste (%)	Macro-F1 teste (%)
Sem grafo	82,58	78,30	76,10
kNN-in	77,63	74,19	70,79
kNN-out	78,44	75,23	72,05
kNN-mutual	79,16	75,62	72,29
kNN-union	78,87	75,60	72,53
DGCG 2-4	80,87	77,19	74,33
DGCG 4-6	79,27	76,05	72,87
DGCG 6-8	77,86	74,89	71,48
DGCG 8-12	74,86	72,21	68,20

Lucas, aqui estão os resultados médios das 10 bases Micro em 27 protocolos (way,shot,query) padrão e sem ponderação

1. Resultados por protocolo

Baselines - acurácia de teste (%) média das dez bases

Way	Shot	Query	Nós	Sem grafo	kNN-in	kNN-out	kNN-mutual	kNN-union
2	1	1	4	81,28	50,00	50,00	50,00	50,00
2	1	5	12	81,71	80,37	82,28	81,90	81,94
2	1	10	22	81,12	82,23	84,52	83,10	85,32
2	5	1	12	88,17	85,03	85,81	87,28	85,06
2	5	5	20	89,11	87,97	88,38	88,76	88,63
2	5	10	30	88,60	88,69	89,11	89,62	89,82
2	10	1	22	89,38	88,78	88,80	89,56	88,78
2	10	5	30	89,84	89,77	89,91	90,25	90,26
2	10	10	40	90,35	89,59	90,15	90,22	90,63
3	1	1	6	71,15	33,33	33,33	33,33	33,33
3	1	5	18	71,91	70,56	72,30	72,03	71,83
3	1	10	33	71,98	72,64	75,98	73,23	76,67
3	5	1	18	80,38	77,72	78,02	80,30	77,45
3	5	5	30	81,91	80,37	81,44	82,16	81,78
3	5	10	45	81,32	80,99	82,18	83,13	83,31
3	10	1	33	82,58	82,14	82,12	82,83	82,81
3	10	5	45	84,08	83,27	83,48	84,16	84,14
3	10	10	60	83,40	83,05	83,56	83,84	84,64
5	1	1	10	60,15	37,65	43,39	43,78	39,19
5	1	5	30	59,59	59,89	61,74	61,20	61,81
5	1	10	55	60,34	61,03	65,10	62,29	66,82
5	5	1	30	71,32	69,48	69,11	71,46	69,25
5	5	5	50	73,98	71,99	72,57	73,85	73,66
5	5	10	75	73,63	72,27	74,08	74,09	74,81
5	10	1	55	74,84	74,40	74,18	76,59	75,51
5	10	5	75	75,28	74,55	74,99	76,36	76,61
5	10	10	100	76,72	75,41	74,68	76,53	77,07

Aqui são os resultados individuais por protocolo nas 10 bases

1. DGCG por grau

Acurácia de teste (%) média das dez bases

Way	Shot	Query	Nós	DGCG 2-4	DGCG 4-6	DGCG 6-8	DGCG 8-12
2	1	1	4	57,44	50,00	50,00	50,00
2	1	5	12	82,93	83,14	80,90	67,70
2	1	10	22	83,37	84,04	84,39	84,14
2	5	1	12	87,61	86,34	84,47	74,29
2	5	5	20	89,04	88,28	87,95	86,76
2	5	10	30	89,87	89,35	89,39	88,89
2	10	1	22	88,83	89,16	88,29	87,22
2	10	5	30	90,36	90,16	89,67	89,19
2	10	10	40	90,01	90,18	90,16	89,72
3	1	1	6	57,66	42,85	33,33	33,33
3	1	5	18	72,80	73,03	70,74	63,24
3	1	10	33	74,02	75,68	75,71	75,05
3	5	1	18	80,66	78,76	76,25	68,47
3	5	5	30	82,03	81,69	80,63	79,14
3	5	10	45	82,90	82,60	82,23	81,81
3	10	1	33	83,04	82,15	82,00	80,65
3	10	5	45	84,18	84,39	83,84	82,70
3	10	10	60	84,46	84,15	84,07	83,66
5	1	1	10	50,52	43,62	39,72	29,24
5	1	5	30	62,14	62,38	60,76	57,09
5	1	10	55	63,74	64,86	65,35	64,82
5	5	1	30	71,63	69,70	67,51	63,79
5	5	5	50	73,53	73,62	72,92	70,81
5	5	10	75	73,97	75,07	74,76	74,09
5	10	1	55	75,65	74,90	74,69	73,05
5	10	5	75	75,97	76,18	75,86	75,19
5	10	10	100	75,82	77,03	76,47	75,73

Para cada protocolo de way-shot-query foram executados 4 diferentes intervalos de grau para o DGCG sendo uma média das 10 bases

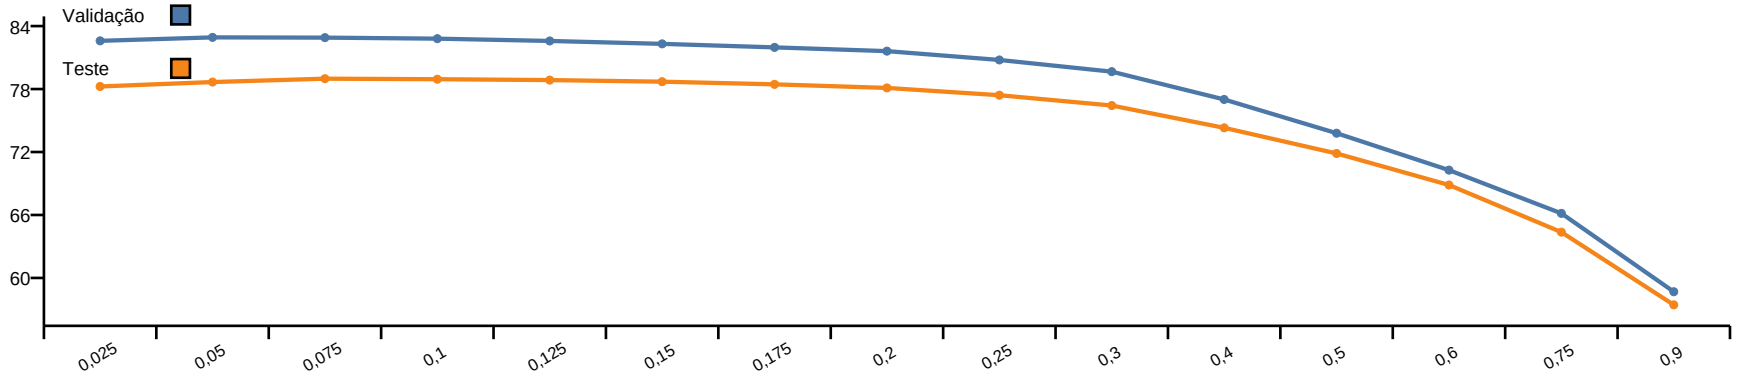
Para episodios com menos de 50 nós, o grau 2-4 geralmente é melhor, mas ao crescer o número de nós o grau 4-6 se torna melhor

2. Varredura de densidade do DGCG

Configuração

Bases	Protocolos	Densidades	Seed	Treino	Dimensão	Execuções
10 bases Micro	27	15	7	2.000 episódios	512 → 256	4.050

DGCG por densidade alvo



Resultados por densidade

Densidade	Validação (%)	Teste (%)	Macro-F1 teste (%)	Vs. DGCG 4-6 (pp)
0,025	82,59	78,24	76,01	+2,20
0,05	82,92	78,67	76,40	+2,62
0,075	82,90	78,99	76,71	+2,94
0,1	82,80	78,94	76,62	+2,89
0,125	82,58	78,85	76,50	+2,81
0,15	82,31	78,70	76,29	+2,65
0,175	81,97	78,45	75,99	+2,40
0,2	81,61	78,11	75,58	+2,06
0,25	80,77	77,41	74,78	+1,36
0,3	79,66	76,43	73,65	+0,38
0,4	77,01	74,30	71,26	-1,74
0,5	73,79	71,86	68,57	-4,19
0,6	70,27	68,86	65,28	-7,19
0,75	66,15	64,36	60,35	-11,68
0,9	58,69	57,44	51,95	-18,61

A mesma coisa da busca com grau, mas dessa vez a busca pela densidade especifica, nas 10 bases e 27 protocolos de way-shot-query, no final compara com o resultado do DGCG 4-6

2. Seleção por validação

Resultados médios das dez bases por protocolo

Way	Shot	Query	Nós	Grau selecionado teste (%)	Ganho (pp)	Densidade selecionada teste (%)	Ganho (pp)
2	1	1	4	57,44	+7,44	82,51	+32,51
2	1	5	12	83,61	+0,48	83,39	+0,25
2	1	10	22	85,00	+0,96	85,60	+1,56
2	5	1	12	87,57	+1,24	88,44	+2,10
2	5	5	20	88,83	+0,55	89,54	+1,26
2	5	10	30	90,04	+0,70	90,17	+0,82
2	10	1	22	88,79	-0,36	89,88	+0,72
2	10	5	30	90,54	+0,38	90,90	+0,73
2	10	10	40	90,41	+0,24	90,28	+0,10
3	1	1	6	57,66	+14,81	71,63	+28,78
3	1	5	18	73,32	+0,30	74,33	+1,30
3	1	10	33	76,32	+0,64	76,38	+0,70
3	5	1	18	80,34	+1,58	81,06	+2,30
3	5	5	30	81,94	+0,25	82,63	+0,94
3	5	10	45	83,09	+0,50	82,86	+0,27
3	10	1	33	83,11	+0,96	83,70	+1,54
3	10	5	45	84,38	-0,00	84,18	-0,21
3	10	10	60	84,72	+0,57	84,53	+0,38
5	1	1	10	50,52	+6,90	60,11	+16,49
5	1	5	30	62,46	+0,08	62,13	-0,25
5	1	10	55	65,31	+0,45	65,47	+0,60
5	5	1	30	71,39	+1,70	72,24	+2,55
5	5	5	50	73,53	-0,09	73,47	-0,14
5	5	10	75	74,71	-0,35	74,70	-0,36
5	10	1	55	75,29	+0,40	75,97	+1,07
5	10	5	75	76,51	+0,33	76,19	+0,02
5	10	10	100	76,43	-0,60	76,42	-0,61

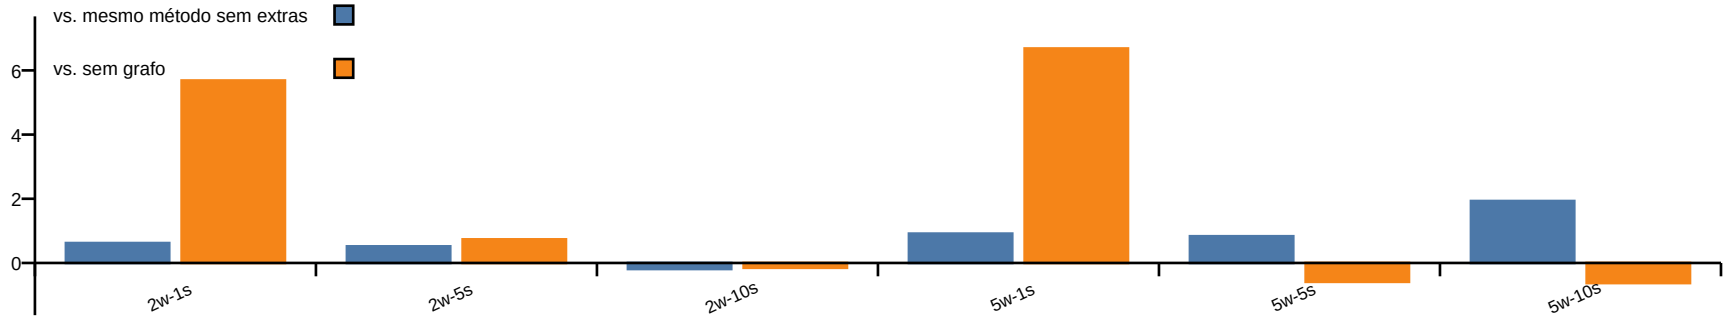
Esse experimento é um pouco mais complicado de explicar.
Para cada protocolo de way-shot-query dito, é realizado os treinos e validações alterando o grau alvo (2-4, 4-6, 6-8, 8-12), depois das 200 validações, seleciona o intervalo que teve a maior validação e calcula o teste.
Isso é feito também para a densidade variando de 0,025 a 0,90. Como essa busca por densidade era mais específica e possui mais valores, para episodios pequenos teve vantagem.
Estou fazendo a busca da densidade não de forma binária, mas uma busca exata.

3. Experimentos com imagens extras

Configuração

Bases	Protocolos	Métodos/alvos	Extras/classe	Fases	Médias	Execuções
10 bases Micro	6	7	0, 5, 10 e 20	treino; treino-val; todas	474	4.740

Melhor configuração com extras escolhida pela validação



A coluna azul é a melhor configuração de extras - a mesma configuração sem extras e a laranja é em relação ao nograph

Controles sem imagens extras - acurácia de teste (%)

Way	Shot	Query	Sem grafo	kNN-in	kNN-out	kNN-mutual	kNN-union	DGCG 2-4	DGCG 4-6
2	1	10	80,57	82,07	85,33	82,42	85,63	83,56	84,12
2	5	10	89,09	88,21	88,81	88,88	89,31	88,35	88,55
2	10	10	90,75	89,67	89,99	90,31	90,79	90,11	90,08
5	1	10	59,53	61,02	64,28	61,58	65,30	62,55	63,97
5	5	10	74,40	71,37	72,33	72,80	72,98	73,07	72,93
5	10	10	76,94	73,15	73,35	74,35	74,08	73,87	74,39

Somente os resultados de controle para comparação com as mesmas configurações

3. Melhores configurações com imagens extras

Configurações escolhidas pela validação

Way	Shot	Query	Método	Alvo	Modo	Fase	Extras/classe	Validação (%)	Teste (%)
2	1	10	knn-union	-	propagation	all	20	89,48	86,25
2	5	10	knn-union	-	propagation	all	20	92,45	89,82
2	10	10	knn-union	-	propagation	all	20	93,47	90,60
5	1	10	knn-union	-	propagation	all	10	74,10	66,21
5	5	10	knn-union	-	propagation	all	10	81,01	73,81
5	10	10	dgcg	4-6	propagation	all	20	83,41	76,32

Comparações

Way	Shot	Teste com extras (%)	Vs. mesmo método sem extras (pp)	Sem grafo (%)	Vs. sem grafo (pp)
2	1	86,25	+0,62	80,57	+5,68
2	5	89,82	+0,52	89,09	+0,74
2	10	90,60	-0,19	90,75	-0,15
5	1	66,21	+0,91	59,53	+6,68
5	5	73,81	+0,83	74,40	-0,59
5	10	76,32	+1,93	76,94	-0,63

Quantidade de execuções

Bloco	Configurações médias	Execuções
Controles sem extras	42	420
Extras na propagação	324	3.240
Extras nos rankings	108	1.080
Total	474	4.740

Esses são os melhores resultados do experimento com imagens extras
Utilizei imagens extras de duas formas - Somente na criação das listas ranqueadas (sem propagar no grafo) ou na criação das listas ranqueadas e na participação da propagação do grafo. A segunda forma foi a melhor configuração, portanto na tabela de cima so temos o modo propagation para não lotar de resultados.

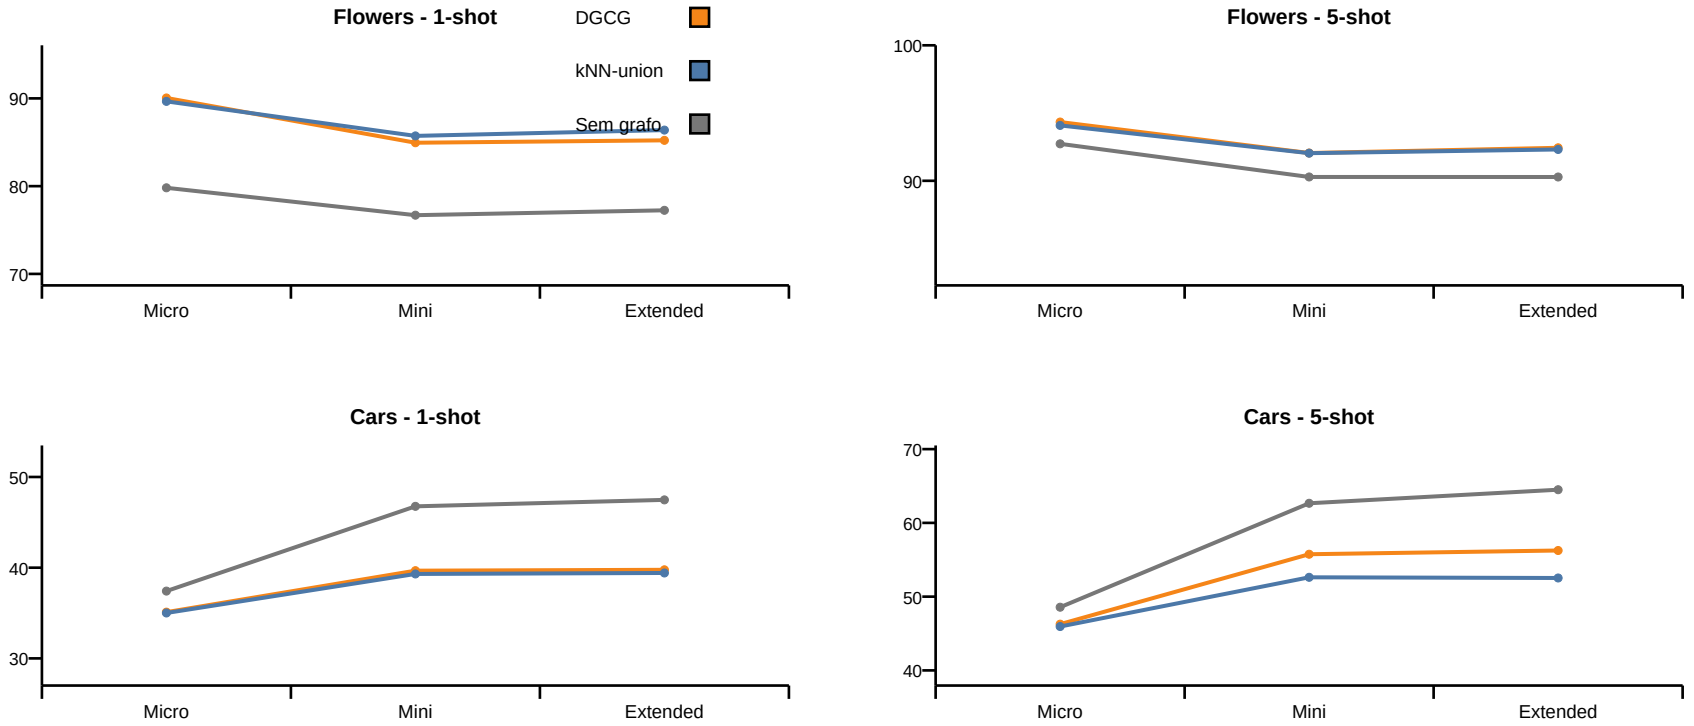
Além disso, temos a fase que utilizei as imagens extras, testei 3 formas: A 1 sendo imagens extras somente no treino, a 2 sendo imagens extras somente no treino e validação e a 3 no treino, validação e teste (all). A 3 forma também foi a melhor sendo so mostrado a fase all. Testei com 5, 10 e 20 imagens extras também.

4. Flowers e Cars em diferentes escalas

Configuração

Versões	Protocolos	Métodos	Seeds	Treino	Dimensão	Execuções
Micro, Mini e Extended	5-way; 1/5-shot; 10-query	DGCG, kNN-union e sem grafo	7, 17 e 27	2.000 episódios	512 → 256	108

Resultados por escala - média das seeds 7, 17 e 27



Aqui é a comparação dos métodos em bases maiores flowers e cars micro, mini e extended.
Importante ressaltar que mesmo a base sendo maior, quem dita o tamanho do episódio é o way-shot-query, portanto os episódios são do mesmo tamanho.

Importante ressaltar também que as densidades do DGCG utilizadas foram calculadas fazendo aquela busca de 15 densidades no Micro da Flowers e do Cars e essa a melhor densidade foi utilizada no Mini e Extended.

Não é muito consistente pois na flowers DGCG ganha as vezes, porém no Cars não.

4. Flowers e Cars em diferentes escalas

Resultados - Flowers

Escala	Shot	Método	Configuração	Validação (%)	Teste (%)	Macro-F1 teste (%)
Micro	1	DGCG	densidade 0,125	91,70 ± 3,53	90,05 ± 3,19	89,34 ± 3,53
Micro	1	kNN-union	-	91,72 ± 1,59	89,66 ± 2,87	89,28 ± 3,14
Micro	1	Sem grafo	-	79,08 ± 3,15	79,81 ± 5,64	78,71 ± 6,03
Micro	5	DGCG	densidade 0,05	95,86 ± 1,32	94,34 ± 2,76	94,31 ± 2,75
Micro	5	kNN-union	-	95,39 ± 1,21	94,09 ± 1,46	94,07 ± 1,48
Micro	5	Sem grafo	-	94,26 ± 1,53	92,73 ± 4,16	92,65 ± 4,23
Mini	1	DGCG	densidade 0,125	85,59 ± 0,67	84,95 ± 3,36	83,79 ± 3,64
Mini	1	kNN-union	-	86,91 ± 0,61	85,73 ± 2,67	85,16 ± 2,82
Mini	1	Sem grafo	-	78,55 ± 1,86	76,69 ± 2,83	75,37 ± 3,15
Mini	5	DGCG	densidade 0,05	92,75 ± 0,63	92,05 ± 1,48	91,89 ± 1,53
Mini	5	kNN-union	-	92,44 ± 0,49	92,04 ± 1,75	91,91 ± 1,84
Mini	5	Sem grafo	-	91,39 ± 1,09	90,28 ± 1,35	90,09 ± 1,38
Extended	1	DGCG	densidade 0,125	85,33 ± 0,97	85,22 ± 2,60	84,05 ± 2,83
Extended	1	kNN-union	-	85,72 ± 0,99	86,39 ± 2,56	85,75 ± 2,77
Extended	1	Sem grafo	-	77,06 ± 2,26	77,25 ± 2,11	76,03 ± 2,36
Extended	5	DGCG	densidade 0,05	92,79 ± 0,69	92,44 ± 1,80	92,28 ± 1,87
Extended	5	kNN-union	-	92,83 ± 0,90	92,31 ± 1,68	92,19 ± 1,73
Extended	5	Sem grafo	-	91,47 ± 0,81	90,28 ± 2,04	90,11 ± 2,08

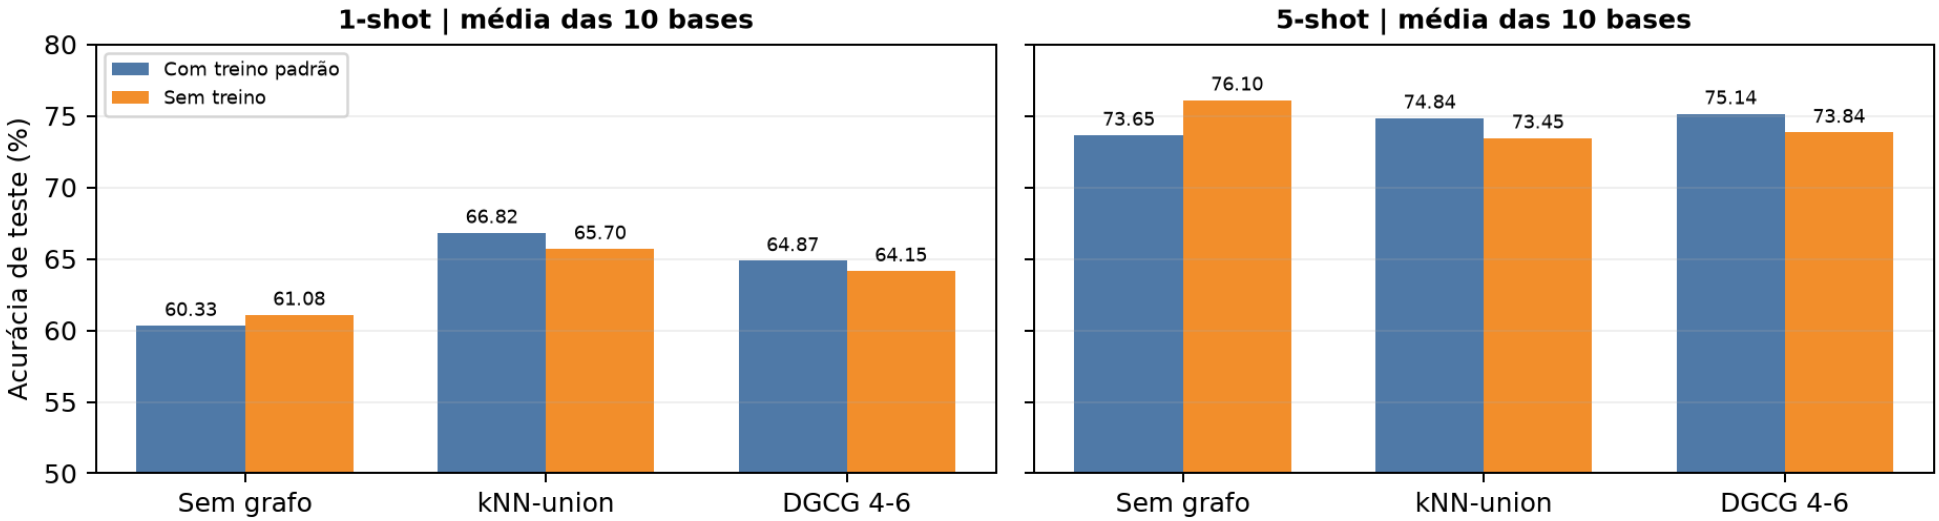
4. Flowers e Cars em diferentes escalas

Resultados - Cars

Escala	Shot	Método	Configuração	Validação (%)	Teste (%)	Macro-F1 teste (%)
Micro	1	DGCG	densidade 0,075	27,39 ± 3,26	35,10 ± 7,63	32,51 ± 7,91
Micro	1	kNN-union	-	27,61 ± 2,75	35,01 ± 7,04	33,26 ± 7,24
Micro	1	Sem grafo	-	28,00 ± 2,35	37,42 ± 7,25	35,30 ± 7,32
Micro	5	DGCG	densidade 0,025	34,16 ± 5,95	46,27 ± 10,23	45,08 ± 10,19
Micro	5	kNN-union	-	34,62 ± 3,09	45,95 ± 9,31	44,71 ± 9,24
Micro	5	Sem grafo	-	34,64 ± 2,21	48,57 ± 9,28	47,69 ± 9,17
Mini	1	DGCG	densidade 0,075	41,98 ± 2,30	39,67 ± 0,98	37,25 ± 0,93
Mini	1	kNN-union	-	41,40 ± 2,52	39,31 ± 1,06	37,71 ± 0,99
Mini	1	Sem grafo	-	48,75 ± 2,12	46,76 ± 1,59	44,91 ± 1,52
Mini	5	DGCG	densidade 0,025	58,28 ± 1,97	55,75 ± 1,73	54,77 ± 1,80
Mini	5	kNN-union	-	54,91 ± 2,56	52,62 ± 1,11	51,49 ± 1,14
Mini	5	Sem grafo	-	64,82 ± 1,30	62,66 ± 2,16	62,01 ± 2,19
Extended	1	DGCG	densidade 0,075	41,47 ± 2,63	39,77 ± 1,37	37,27 ± 1,43
Extended	1	kNN-union	-	41,41 ± 2,28	39,42 ± 1,31	37,85 ± 1,33
Extended	1	Sem grafo	-	49,97 ± 2,59	47,47 ± 1,64	45,68 ± 1,56
Extended	5	DGCG	densidade 0,025	58,72 ± 1,74	56,25 ± 1,32	55,31 ± 1,32
Extended	5	kNN-union	-	54,93 ± 2,07	52,53 ± 1,22	51,50 ± 1,27
Extended	5	Sem grafo	-	66,64 ± 1,67	64,50 ± 2,27	63,91 ± 2,25

5. Experimento sem treino

Bases	Protocolo	Seed	Embedding	Treino	Execuções
10 bases Micro	5-way; 1/5-shot; 10-query	7	512 sem treino; 256 treinado	Sem treino vs. treino com 2.000 episódios	120



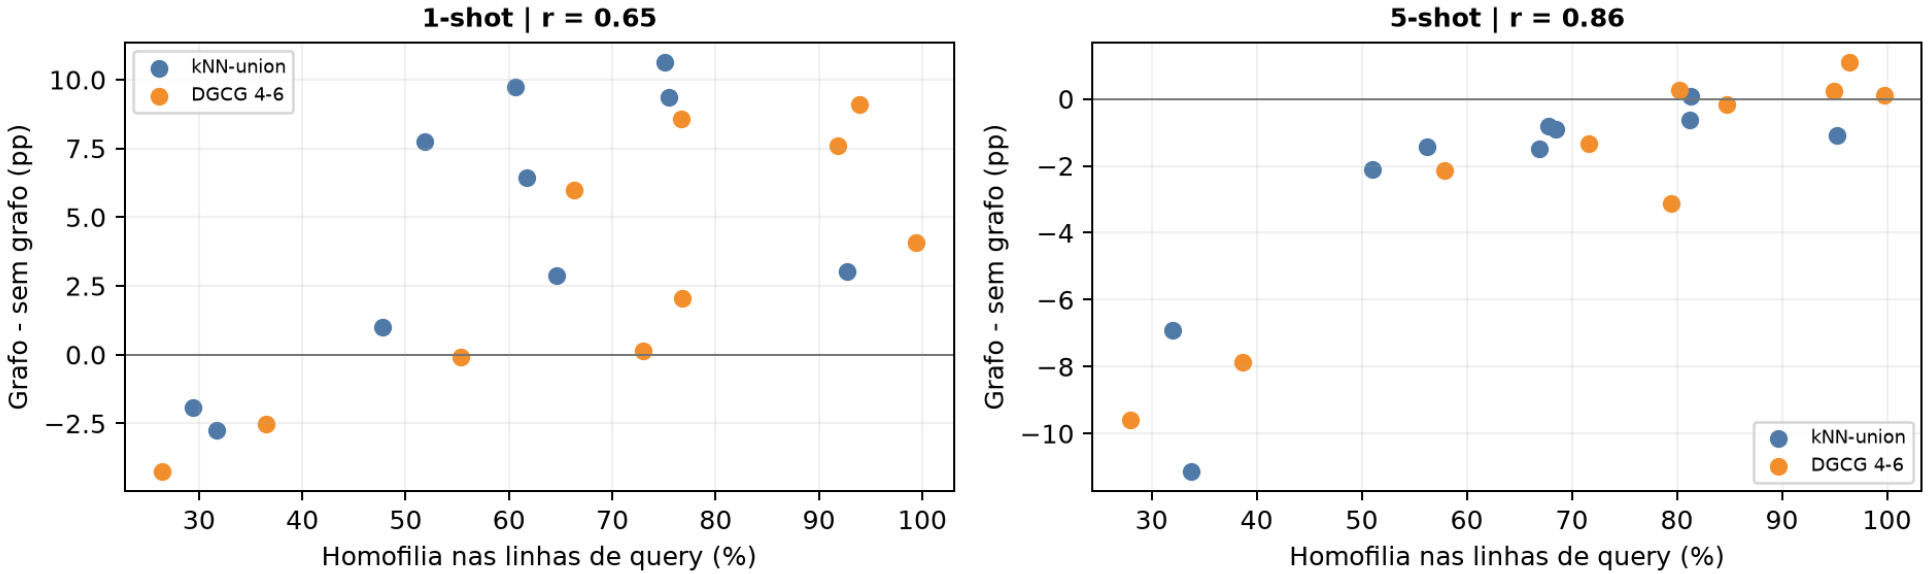
Resultados médios das dez bases

Shot	Método	Condição	Validação (%)	Teste (%)	Macro-F1 teste (%)	Treino - sem treino (pp)
1	Sem grafo	Com treino padrão	65,81	60,33	58,60	-0,75
1	Sem grafo	Sem treino	66,41	61,08	59,41	-
1	kNN-union	Com treino padrão	72,32	66,82	65,54	+1,12
1	kNN-union	Sem treino	70,86	65,70	64,46	-
1	DGCG 4-6	Com treino padrão	70,63	64,87	62,68	+0,71
1	DGCG 4-6	Sem treino	68,80	64,15	61,93	-
5	Sem grafo	Com treino padrão	78,95	73,65	72,89	-2,45
5	Sem grafo	Sem treino	80,98	76,10	75,60	-
5	kNN-union	Com treino padrão	80,04	74,84	74,02	+1,39
5	kNN-union	Sem treino	77,87	73,45	72,60	-
5	DGCG 4-6	Com treino padrão	79,71	75,14	74,20	+1,30
5	DGCG 4-6	Sem treino	78,21	73,84	73,01	-

Resultado interessante, mas testado somente em uma seed (ainda não testei em mais). Sem treino, utilizando somente centróide das resnet padrão, vários resultados superam com treinamento. Próxima etapa seria testar com outros descritores.

6. Experimento de homofilia

Bases	Protocolo	Seed	Embedding	Treino	Execuções
10 bases Micro	5-way; 1/5-shot; 10-query	7	512	Sem treino; 2 propagações (K=2)	40 + diagnóstico



Correlação conjunta nos 20 pontos: r = 0,65 em 1-shot e r = 0,86 em 5-shot

Resultados médios das dez bases

Shot	Método	Homofilia média (%)	Teste (%)	Sem grafo (%)	Ganho vs. sem grafo (pp)
1	kNN-union	59,09	65,70	61,08	+4,62
1	DGCG 4-6	69,61	64,15	61,08	+3,07
5	kNN-union	63,38	73,45	76,10	-2,65
5	DGCG 4-6	73,17	73,84	76,10	-2,25

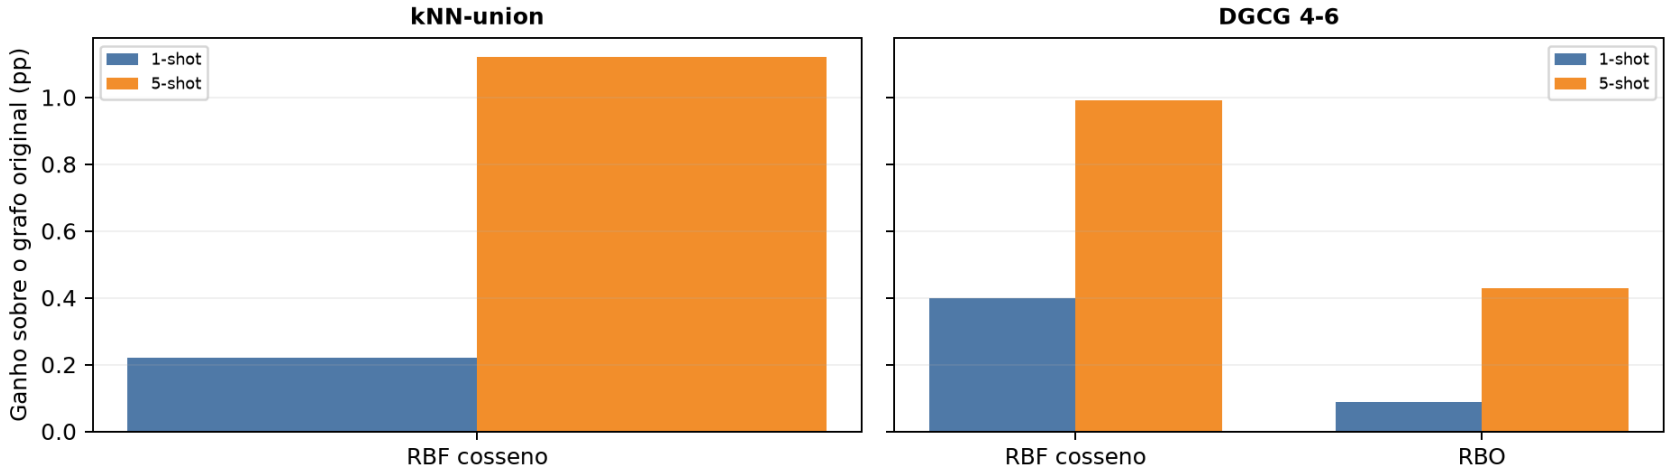
Definição usada

Métrica	Cálculo	Episódios
Homofilia das queries	Fração do peso das arestas que liga imagens da mesma classe, sem autolaços	200 por base e grafo

aqui o correlation r significa correlação Pearson, a proxima etapa seria avaliar se a homofilia pode influenciar utilizar grafo ou não. Falta ainda testar a homofilia com treinamento para ver se segue o mesmo padrão

7. Experimento de ponderação das arestas

Bases	Protocolo	Seed	Embedding	Treino	Execuções
10 bases Micro	5-way; 1/5-shot; 10-query	7	512 sem treino; 256 treinado	Sem treino e confirmação treinada	140



Ponderações sem treino - média das dez bases

Método	Ponderação	Teste 1-shot (%)	Ganho 1-shot (pp)	Teste 5-shot (%)	Ganho 5-shot (pp)
kNN-union	Original	65,70	+0,00	73,45	+0,00
kNN-union	RBF cosseno	65,92	+0,22	74,57	+1,12
DGCG 4-6	Original	64,15	+0,00	73,84	+0,00
DGCG 4-6	RBF cosseno	64,55	+0,40	74,84	+0,99
DGCG 4-6	RBO	64,24	+0,09	74,27	+0,43

Confirmação com treino - somente RBF cosseno

Shot	Método	Grafo treinado original (%)	RBF cosseno treinado (%)	Ganho (pp)
1	kNN-union	66,82	66,91	+0,09
1	DGCG 4-6	64,87	65,27	+0,40
5	kNN-union	74,84	75,78	+0,94
5	DGCG 4-6	75,14	75,81	+0,67

Homofilia e seleção de grafo

Consolidação das baterias anteriores e dos 60 treinos da VM. A análise nova usa 5-way, 1/5-shot e 10 queries por classe.

O que já estava estabelecido

Bloco no PDF anterior	Resultado de referência	Onde conferir na planilha
1. Grafos e graus	Na média dos 27 protocolos, sem grafo fez 78,30%, DGCG 2-4 fez 77,19% e DGCG 4-6 fez 76,05%.	Por bateria → 01 Grafos e graus. Oficial → Resultados, linhas 5-13.
2. Densidade e validação	Entre 15 alvos fixos, 0,075 deu 78,99% de teste. Densidade selecionada pela validação deu 79,58% na média dos 27 protocolos.	Por bateria → 02 Densidades, 03 Grau por validação e 04 Densidade por validação. Oficial → linhas 32-37 para seleção.
3. Imagens extras	No 5-way/5-shot, o melhor resultado listado foi 73,81%, com +0,83 pp sobre o mesmo método sem extras e -0,59 pp frente ao sem grafo.	Por bateria → 14 Imagens extras. Oficial → aba Extras.
4. Escalas das bases	Em Cars, sem grafo venceu kNN e DGCG nas três escalas e nos dois shots. Flowers teve casos em que os grafos ficaram à frente.	Por bateria → 13 Escalas das bases. Oficial → Resultados, linhas 124-159.
5 e 6. Treino e homofilia	Sem treino em 5-shot, o sem grafo fez 76,10%. Ganho do grafo e homofilia tiveram associação positiva mesmo com perdas em várias bases.	Por bateria → 05 Treino e normalização e 09 Arestas sem treino. Oficial → linhas 38-49.
7. Ponderação	No 5-shot com treino, RBF cosseno ganhou +0,94 pp no kNN e +0,67 pp no DGCG sobre suas versões originais.	Por bateria → 09 Arestas sem treino e 10 Arestas com treino. Oficial → linhas 80-119.

O que a bateria nova acrescentou

Registramos a acurácia do sem grafo e dos dois grafos ao longo de 2.000 episódios. Com os registros, simulamos uma decisão antes do treino usando a homofilia de 30 episódios.

As numerações do PDF anterior e das abas por bateria são diferentes. O índice da página 6 identifica os arquivos e os filtros.

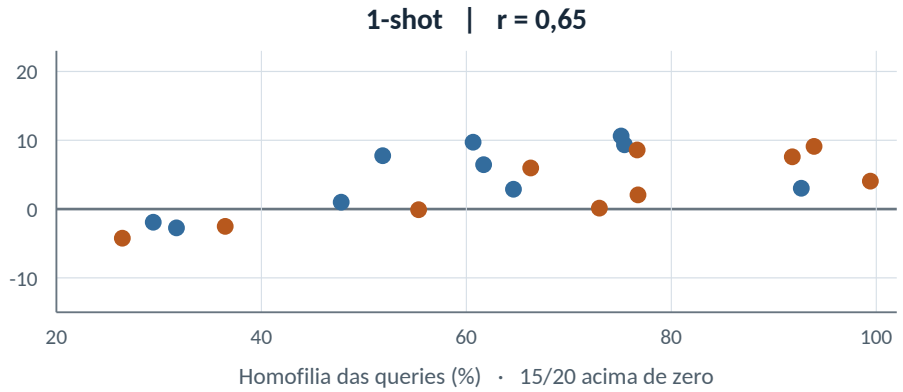
O que mudou com a projeção treinada

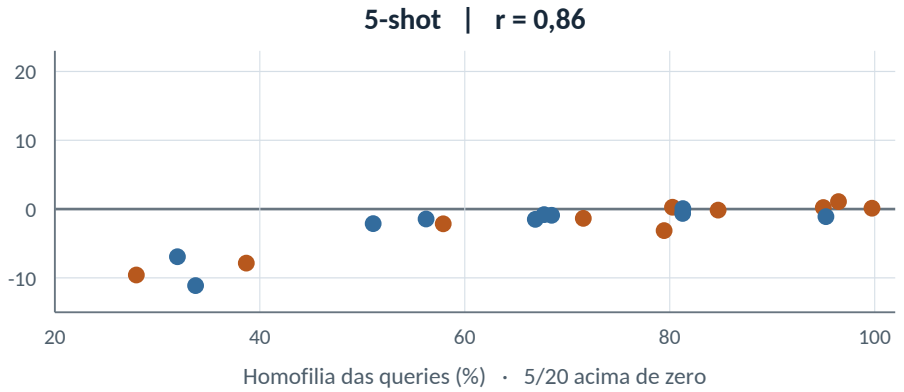
Cada ponto é uma base e um método. A linha zero representa a acurácia do sem grafo na mesma base e no mesmo cenário.

Eixo vertical · Acurácia do grafo menos a do sem grafo (pp)

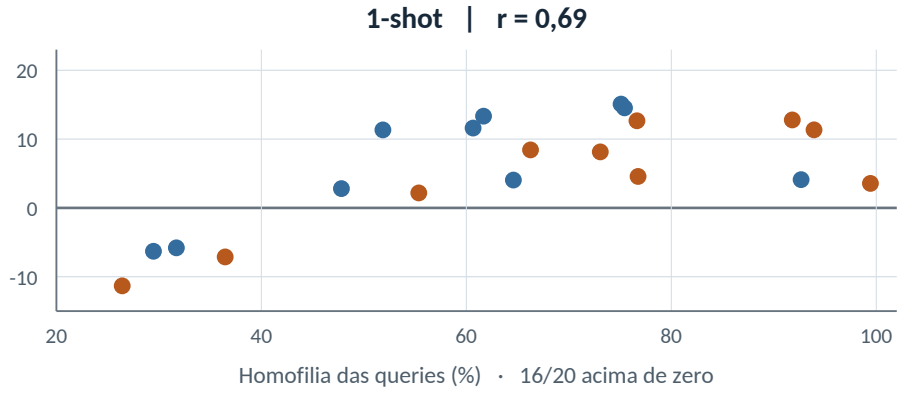
kNN-union DGCG 4-6

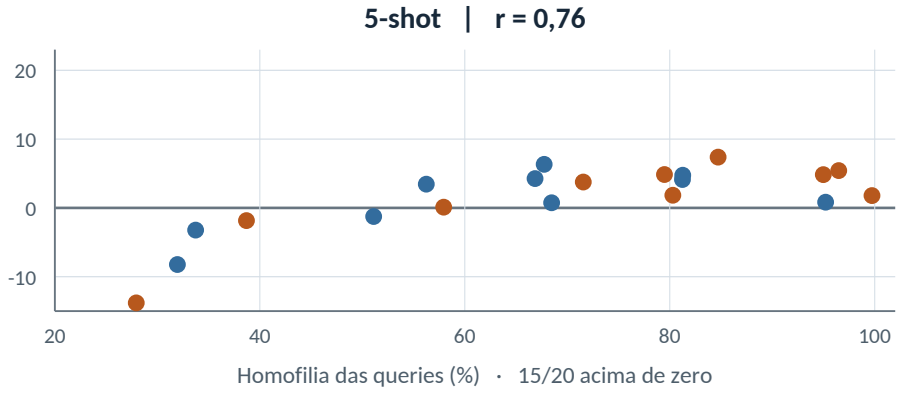
SEM TREINO | CPU, 512 DIM.





COM TREINO | CUDA, PROJEÇÃO 256 DIM.



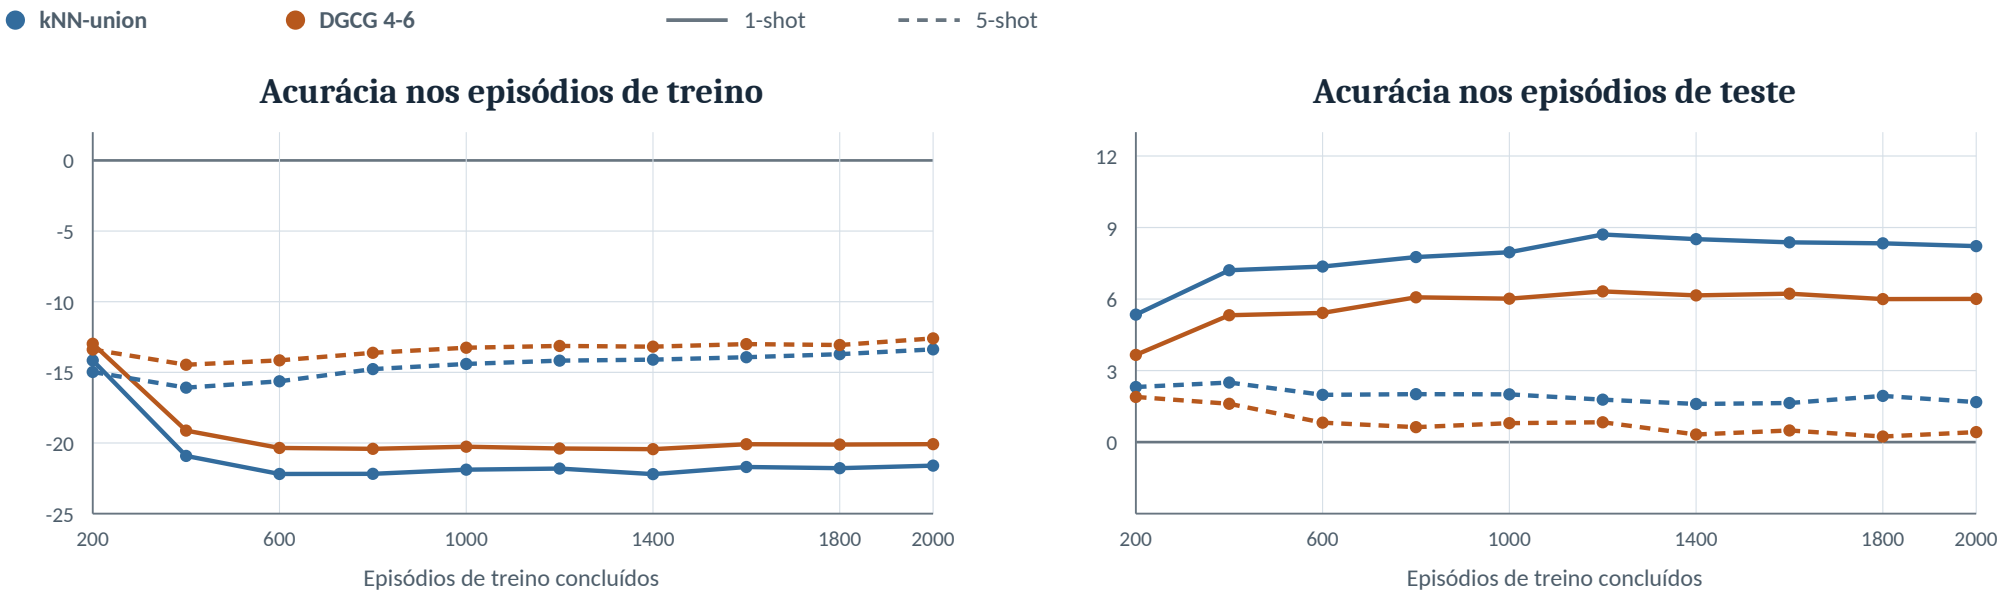


Homofilia das queries é a fração das conexões que chegam a queries e ligam imagens da mesma classe, sem autolaços. A outra ponta pode ser suporte ou query. O diagnóstico usa 200 episódios de teste por condição.

O histórico vem da aba 09 da planilha por bateria e de res_topo_tf.jsonl. Os dados da VM estão em pontos_homofilia.csv e correlacoes.csv. A página 5 mostra também a comparação histórica feita inteiramente em CPU.

Quando o grafo passou o sem grafo?

Cada curva é a média das 10 bases. O controle sem grafo também treinou a projeção, na mesma sequência de episódios.



Valores em pontos percentuais de acurácia acima ou abaixo do sem grafo.

Primeira vantagem no teste	Episódio 200	Episódio 400	Episódio 1.000	Sem vantagem observada
Comparações (40 no total)	29	3	1	7

No treino, 0 de 40 tiveram vantagem em algum bloco de 200 episódios. Ainda assim, a correlação entre homofilia e ganho no treino foi positiva em **40 de 40** ao olhar episódio por episódio. No teste ao longo do treino, a correlação por bloco foi positiva em **19 de 40**.

Entre bases, a homofilia média dos episódios de treino acompanhou o ganho no teste final (r = 0,75 em 1-shot e 0,79 em 5-shot, combinando kNN e DGCG). Isso motivou a regra de seleção.

Na VM, os dados estão em curva_blocos.csv, primeira_vantagem.csv e correlacoes_entre_bases.csv. Teste a cada 200 episódios, com os mesmos 1.000 episódios por condição ao longo dos checkpoints.

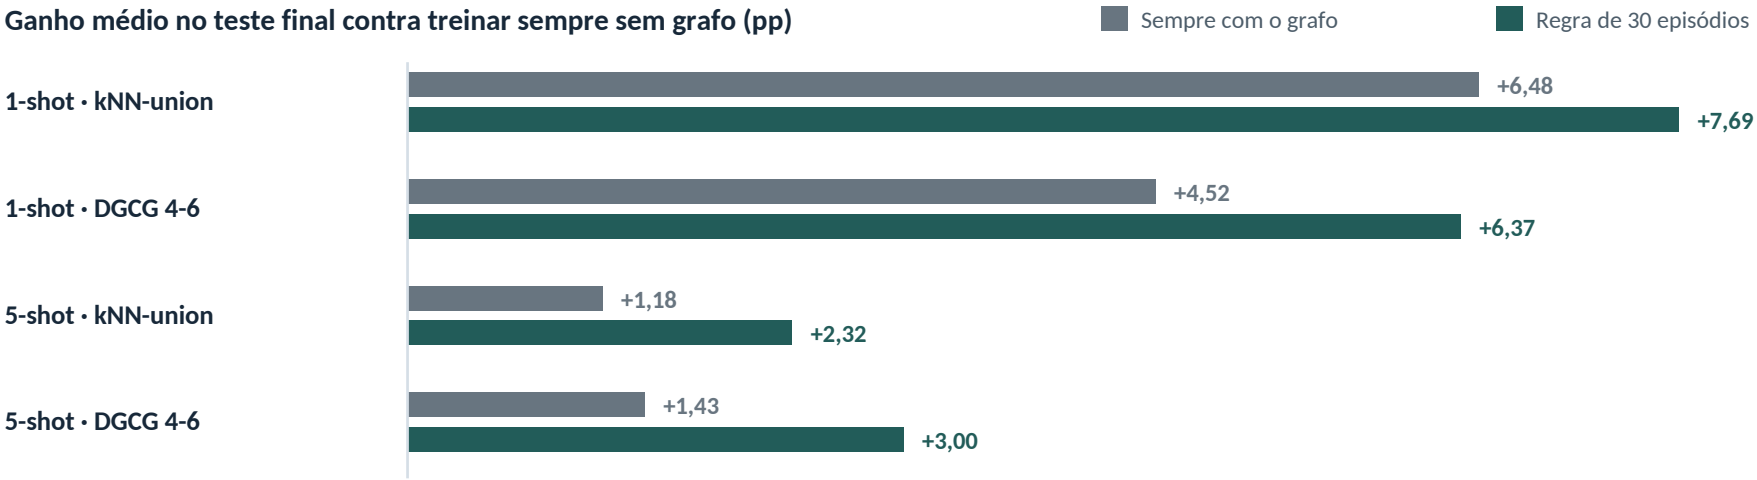
O que 30 episódios já conseguem indicar

Simulação retrospectiva. Para cada base, o corte que maximizava o ganho médio de teste foi escolhido nas outras nove bases.

Regra avaliada para cada método e shot

1. Montar o grafo nos primeiros 30 episódios de treino com a ResNet congelada. **2.** Medir a homofilia das queries com os rótulos de treino. **3.** Abaixo do corte, escolher sem grafo. A partir do corte, manter o grafo. Só depois consultar o teste da base separada.

Ganho médio no teste final contra treinar sempre sem grafo (pp)



Cars 5-shot com kNN

Homofilia de **35,2%** contra corte de **49,3%** aprendido nas outras bases. A regra escolheu sem grafo. No teste, o kNN perdeu **3,23 pp** para o sem grafo.

Nos primeiros 30 episódios, a regra dispensou o grafo em **Cars e Textures** nas quatro condições. Em 1.000 sorteios de 30 episódios já registrados, a média da regra superou a do grafo fixo em todas as condições. Em Plankton 5-shot, porém, a regra dos primeiros 30 manteve o kNN e perdeu 1,25 pp.

Os sorteios verificam a estabilidade da amostra dentro das mesmas bases (seed 7). O limiar permanece exploratório para uma base inédita. A regra foi recalculada a partir de curva_episodios.csv e resultados_homo.csv.

O sem treino continua na comparação

Médias nas 10 bases. A comparação histórica em CPU e a rodada nova em CUDA aparecem em colunas separadas.

Cenário	Método	CPU sem treino	CPU com treino	VM com treino	Treino − sem treino (CPU, pp)
1-shot	Sem grafo	61,08%	60,33%	60,34%	-0,75
1-shot	kNN-union	65,70%	66,82%	66,82%	+1,12
1-shot	DGCG 4-6	64,15%	64,87%	64,86%	+0,71
5-shot	Sem grafo	76,10%	73,65%	73,63%	-2,45
5-shot	kNN-union	73,45%	74,84%	74,81%	+1,39
5-shot	DGCG 4-6	73,84%	75,14%	75,07%	+1,30

Em 5-shot, sem treino e sem grafo fez 76,10%, acima de todas as opções fixas com treino na tabela. Na simulação, treinar com DGCG só quando a regra indica e treinar sem grafo nas outras bases deu **76,63%**. A diferença de **+0,53 pp** cruza o histórico em CPU e a rodada em CUDA e vem de uma seleção retrospectiva.

A CPU está na aba Resultados da planilha oficial (linhas 38-49) e a VM em resultados_homo.csv. A simulação soma o ganho da regra da página 4 ao resultado sem grafo em CUDA.

Dois testes para avançar

1. Decidir se vale treinar. Reaproveitar os resultados por base de **res_e1.jsonl**, que tem opções com e sem treino em CPU. Incluir o sem treino como opção da regra e medir a acurácia na base deixada de fora. Depois, congelar a regra e verificar em bases inéditas, com novas seeds e comparação no mesmo ambiente.

2. Decidir quando só há rótulos do suporte. O teste dos 30 episódios usa os rótulos de treino das queries. A aba 12 já mediu, em 5-shot e sem treino, a relação entre a homofilia dos suportes e das queries. A correlação das médias entre bases foi acima de 0,99 para os dois grafos, enquanto a mediana da correlação por episódio ficou perto de zero. Falta testar diretamente se a média do suporte ajuda a escolher o método.

O diagnóstico de suporte vem da aba 12 Homofilia dos suportes e de res_supproxy.json. Em 1-shot, uma aresta entre suportes distintos sempre liga classes diferentes.

Onde encontrar cada resultado

Use as abas da planilha para o histórico e os CSVs da VM para as curvas novas. Os nomes e filtros abaixo permitem reproduzir as comparações.

Planilha oficial · resultados_fewshot_fonte_unica.xlsx

Planilha por bateria · resultados_fewshot_por_bateria.xlsx

Relatório anterior · experimentos_baterias_1a7_Gabriel (2).pdf

Resultado	Arquivo / aba	Filtro ou colunas principais
Histórico: treino × sem treino	Oficial → Resultados, linhas 38-49. Por bateria → 05 Treino e normalização.	IDs CLAUDE-E1, normalização raw. TR256 = treino, TF512 = sem treino.
Gráfico antigo de homofilia	Por bateria → 09 Arestas sem treino. PDF anterior, p. 12.	kNN-union e DGCG 4-6 originais, em 1-shot e 5-shot. Usar homofilia das queries.
Teste final e homofilia da VM	resultados_homo.csv e pontos_homofilia.csv.	dataset, shot, method, test_percent, homophily_query_percent e gain_pp no arquivo de pontos.
Curvas e primeira vantagem	curva_blocos.csv e primeira_vantagem.csv.	gain_train_pp e gain_test_pp; first_train_lead_end e first_test_lead_checkpoint. Campos vazios indicam ausência de vantagem.
Regra dos 30 episódios	curva_episodios.csv + resultados_homo.csv.	episode de 1 a 30. Razão entre a soma de same_query e a soma de weight_query. Parear por dataset, shot, seed e method.
Diagnóstico só do suporte	Por bateria → 12 Homofilia dos suportes.	5-shot para kNN-union e DGCG. Homofilia média dos suportes, média das queries e correlação por episódio.

VM. ResNet-18 ImageNet congelada, imagens 128 × 128, projeção 512 para 256, 2.000 episódios, seed 7. São 10 bases × 2 shots × 3 métodos, com 1.000 episódios por avaliação de teste. Os 40 modelos com grafo também têm 200 episódios de teste para o diagnóstico de homofilia.

Os resultados novos da VM e a simulação estão referenciados pelas fontes CSV. As planilhas históricas foram consultadas para este relatório.

Índice de todas as baterias

As páginas 1 a 19 preservam integralmente os dois relatórios. Este índice localiza os experimentos complementares e a planilha de cada bateria.

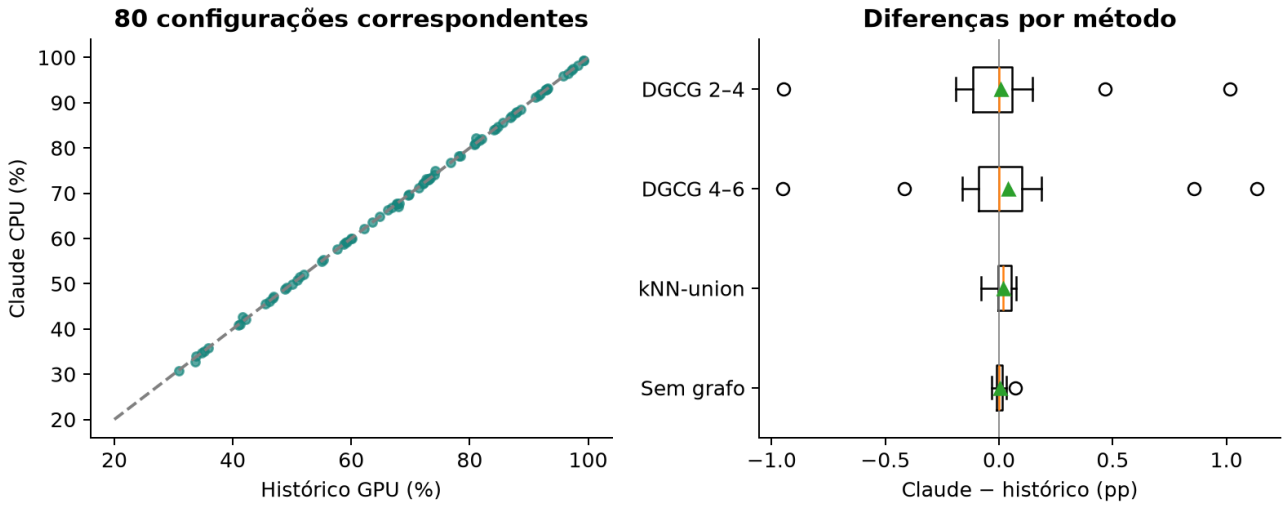
Abas da planilha por bateria	Estudo	Páginas no PDF combinado
01 a 04	Grafos, faixas de grau, densidades e seleção por validação	1-5
05	Treino e normalização das features	11, 18, 23
06 a 08	DGCG 2-4, inicialização identidade, saltos e intensidade	22, 24-25
09 e 10	Arestas, ponderação e homofilia sem treino	12-13, 15, 26-27
11 e 12	Propagação adaptativa e homofilia dos suportes	28-30
13 e 14	Escalas das bases e imagens extras	6-10
15	Contexto de queries	31
16	Comparação de features ResNet-18 e ViT-B/16	32-33
CSV da reprodução	Conferência CPU local × GPU da VM	21
CSV da VM	Homofilia com treino, curvas e regra de 30 episódios	14-19
Fontes complementares	Ajuste piloto, rankings globais, extras piloto e homofilia em CPU	34

Dados completos por condição

Nos **Anexos** do leitor de PDF estão as duas planilhas originais e um ZIP com os dados das baterias novas, da conferência CPU/GPU e dos testes exploratórios. Na planilha por bateria, a aba **Todos os experimentos** permite filtrar por base, protocolo, método e seed.

As páginas 21 a 30 vêm do guia histórico entendendo_resultados_fewshot.pdf e mantêm a numeração impressa do guia. Use a numeração do leitor ou os marcadores do PDF combinado.

CPU local e GPU da VM: os resultados se reconhecem



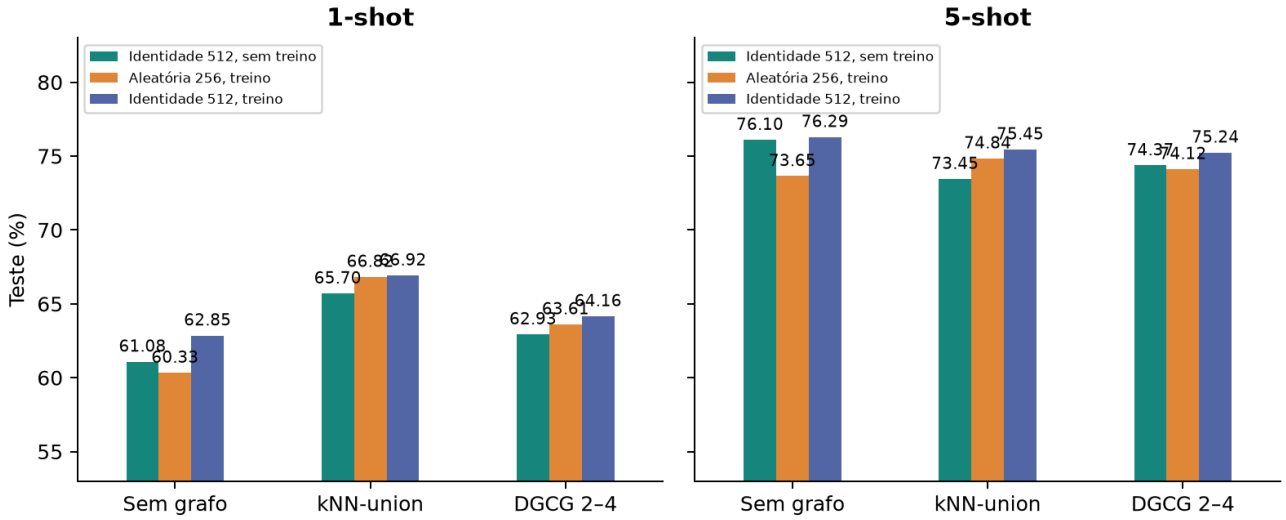
Como ler: à esquerda, cada ponto é uma configuração correspondente; a diagonal representa resultados idênticos.. À direita, zero significa ausência de diferença entre Claude e histórico.. Cada método reúne 20 pares: dez bases × dois shots..

Nos 80 pares, a diferença absoluta média é 0,119 pp.. As maiores diferenças absolutas são 0,072 pp no no-graph, 0,078 no union, 1,134 no DGCG 4–6 e 1,014 no DGCG 2–4.. As conclusões gerais são compatíveis, mas não há igualdade numérica completa..

Hipótese: diferenças numéricas, bibliotecas e desempates em rankings podem afetar mais um grafo discreto.. Porém, CPU/GPU não foi isolado experimentalmente; não podemos atribuir toda diferença ao dispositivo.. Isso exigiria mesmas features, episódios, código e configuração em ambos os ambientes..

O contraste “com treino × sem treino” do Claude ocorre dentro da CPU.. A troca de dispositivo não explica esse contraste interno..

A identidade muda a história do treino

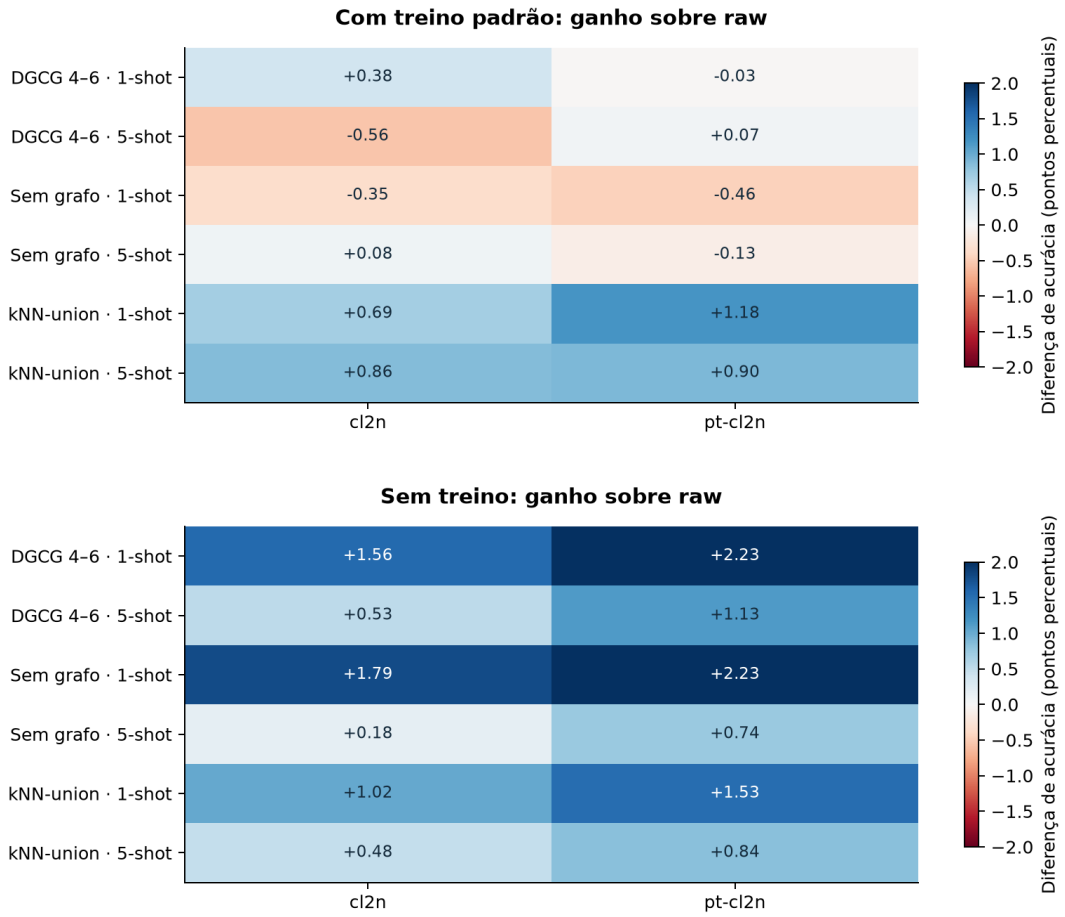


Três condições: identidade 512 sem treino; projeção aleatória 256 com treino padrão; identidade 512 com treino.. No-graph passa de 61,08 para 62,85% no 1-shot e de 76,10 para 76,29% no 5-shot ao treinar a condição iniciada na identidade..

Isso enfraquece bastante a interpretação de que “aprender é o problema”.. Preservar o ponto de partida parece importante.. A comparação identidade 512 com/sem treino é mais direta; já identidade 512 versus aleatória 256 muda dois fatores simultaneamente.. Separar dimensão de inicialização exige aleatória 512 + treino e um controle adequado de projeção 256..

Detalhe essencial: “sem treino” ainda aplica LayerNorm inicializada e normalização L2.. O rótulo raw significa ausência de CL2N/PT antes da cabeça, não ausência de qualquer transformação.. Aqui o DGCG é 2–4, pois é a variante executada no estudo de identidade..

Há dois cuidados escondidos no pipeline

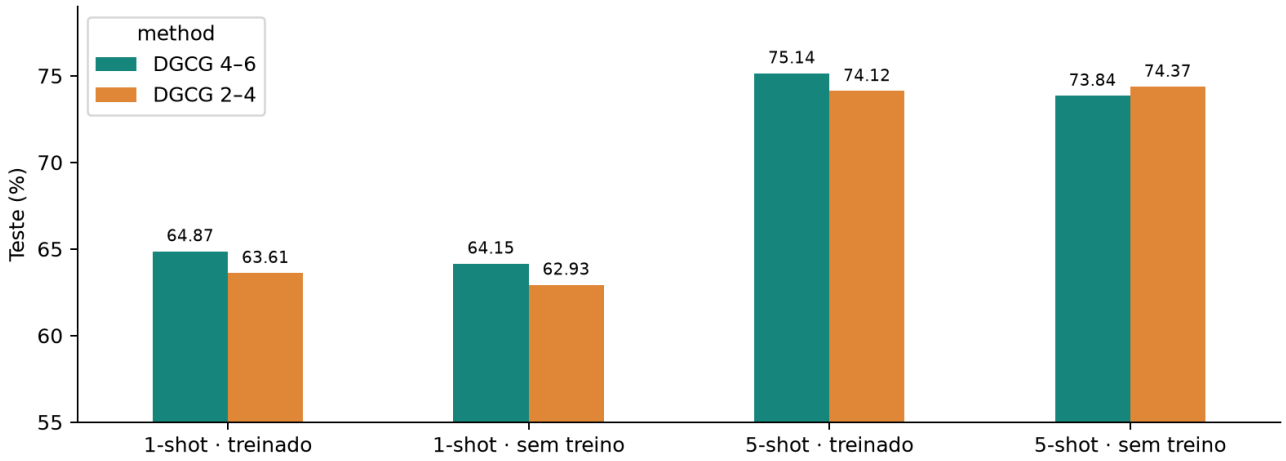


CL2N: subtrai o centro calculado nas features de treino e normaliza cada vetor.. PT+CL2N: aplica raiz quadrada aos valores não negativos antes de centralizar/normalizar.. Nos gráficos, zero é o raw do mesmo método e shot.. Melhorias pequenas ou dependentes da condição não justificam dizer que uma transformação vence sempre..

Checkpoint inicial: o código começa com melhor validação = $-\infty$ e só avalia depois de treinar.. Assim, o estado inicial não concorre com os checkpoints treinados.. “Melhor checkpoint” significa melhor entre os checkpoints avaliados, não melhor que o ponto de partida.. Avaliar o episódio zero é um controle prioritário..

O que o otimizador altera: Θ, escala/deslocamento da LayerNorm e escala dos logits.. A escala positiva dos logits não muda o argmax com distâncias fixas, mas participa dos gradientes.. Atribuir toda melhora ou queda apenas a Θ seria incompleto..

DGCG 2–4 ou 4–6: depende do tamanho do episódio



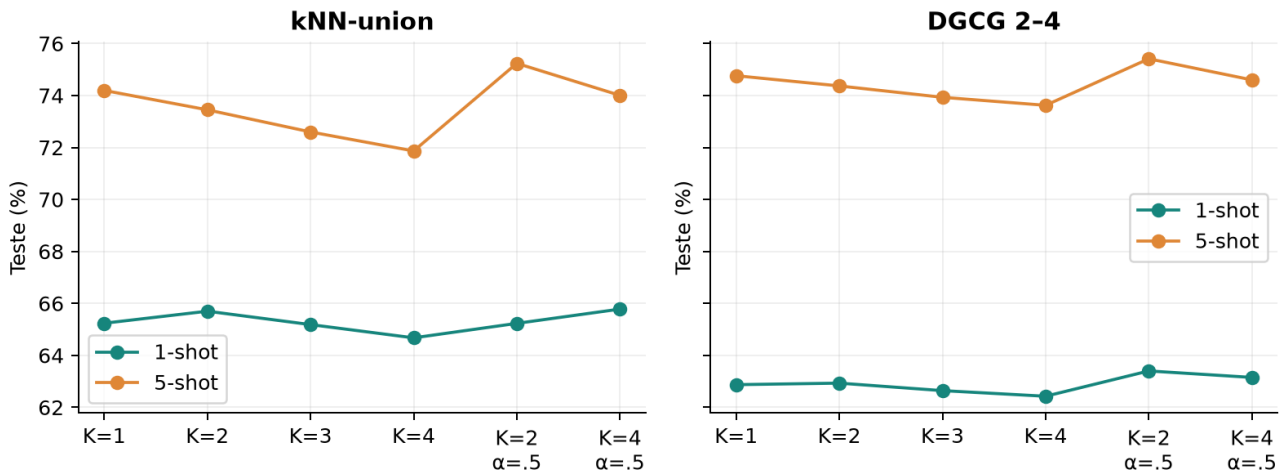
Como ler: cada grupo mantém shot e condição de treino; só muda a faixa de grau do DGCG.. Aqui os episódios têm 55 ou 75 nós.. Com treino, 4–6 supera 2–4 na média: 64,87 versus 63,61% no 1-shot; 75,14 versus 74,12% no 5-shot..

Isso não contradiz o histórico em que faixas menores podiam ser melhores em protocolos muito pequenos.. Uma conexão extra em um grafo com poucos nós muda muito sua densidade; em um episódio maior, uma faixa muito baixa pode limitar a informação que circula..

Limite da conclusão: o resultado apoia dependência do protocolo, não uma lei de que grau ideal cresce sempre com o número de nós.. Shot, número de classes, qualidade das features e construção do grafo também mudam a tarefa.. Densidade escolhida por validação é outra configuração; não deve ser confundida com DGCG fixo 4–6..

Escolher a melhor faixa por teste seria otimista.. A escolha de hiperparâmetros deve continuar na validação..

Mais propagação nem sempre traz mais informação

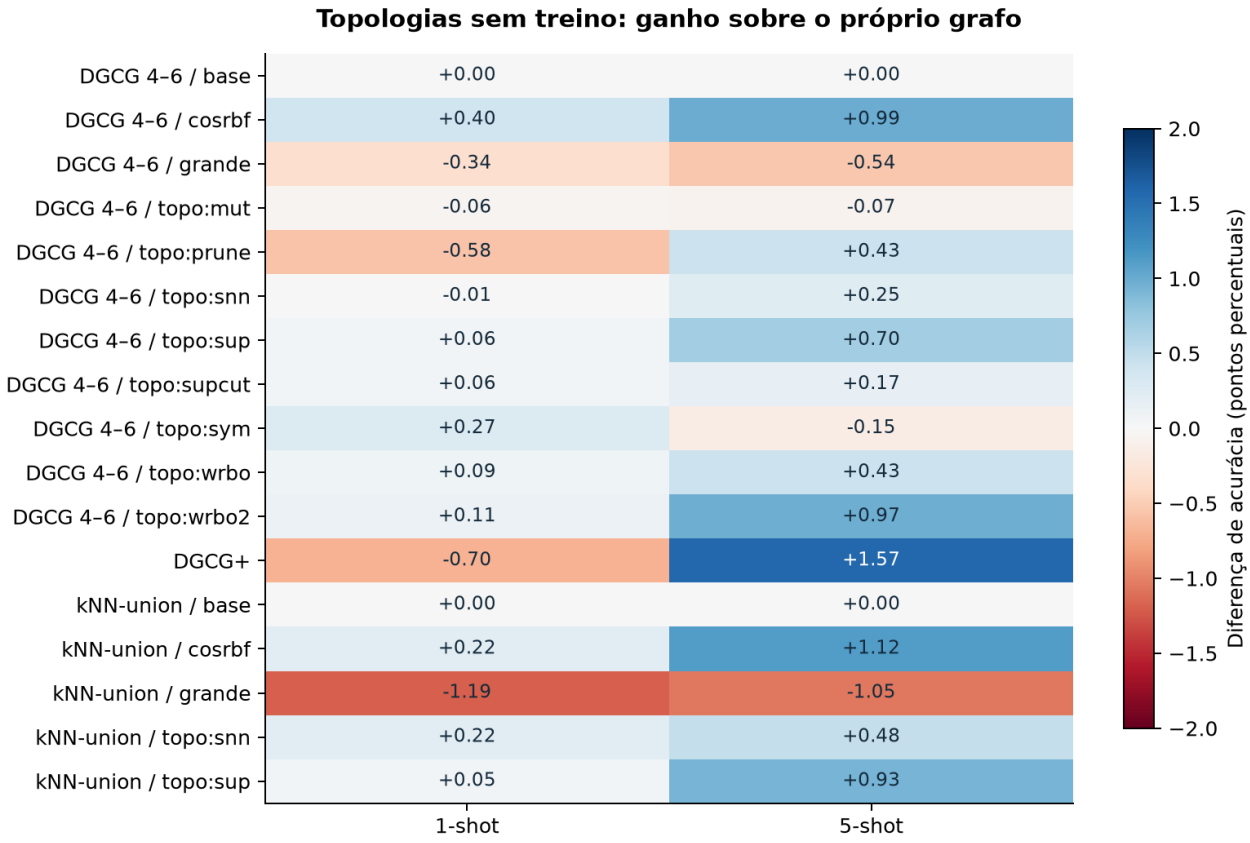


K é o número de saltos.. Em K=2, cada nó pode receber informação por caminhos de dois passos.. A mistura usa A efetiva = (1−α)Â + αI antes dos saltos; α=0,5 preserva mais a própria representação.. Não é uma média final entre duas classificações prontas..

No union 5-shot, aumentar de dois para quatro saltos reduz a média de 73,45 para 71,87%.. Usar α=0,5 com dois saltos recupera para 75,24%, ainda abaixo do no-graph 76,10%.. No 1-shot, as mudanças são bem menores na média..

Hipótese coerente: mistura excessiva pode apagar distinções entre classes ou espalhar ligações erradas.. A queda com mais saltos e a recuperação com identidade são evidências compatíveis com esse mecanismo, mas não o comprovam sozinhas.. Para testar, medir separação intra/interclasse e erros por query antes e depois de cada salto..

Qualidade da aresta: o que cada intervenção fez

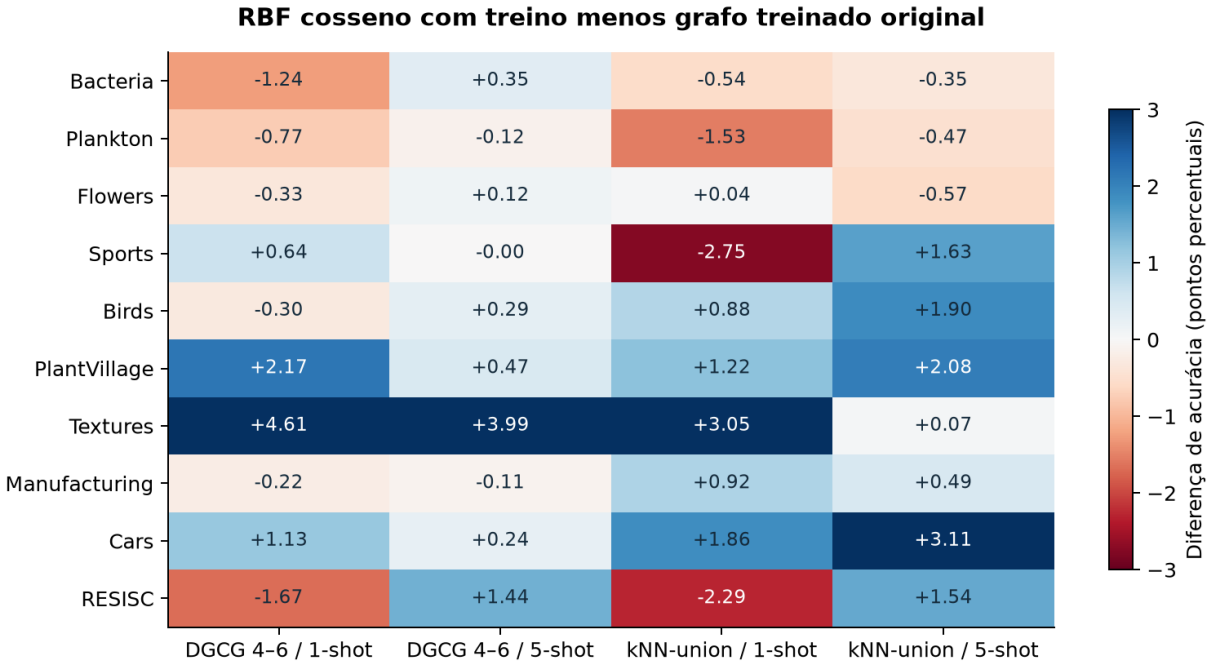


Como ler: diferenças contra o próprio grafo original, em raw e sem treino.. Azul significa recuperação; não significa superar o no-graph.. DGCG+ é comparado ao DGCG 4–6..

Pesos: RBO/RBO² usam concordância de rankings; SNN usa vizinhos compartilhados; cosrbf usa similaridade cosseno convertida em peso.. Estrutura: sym une sentidos, mut mantém reciprocidade, prune remove ligações com RBO baixo.. Suportes: sup substitui seu bloco por ligações de mesma classe, supcut apenas remove ligações entre classes distintas nesse bloco.. DGCG+ e GRaNDe são variantes adicionais do construtor avaliadas pelo harness..

O sinal mais consistente é pesar conexões no DGCG 5-shot: cosrbf e RBO² recuperam aproximadamente 1 pp; DGCG+ chega a +1,57 pp, mas sua média 75,42% ainda fica abaixo de 76,10% sem grafo.. A poda melhora cerca de 0,43 pp no 5-shot e piora no 1-shot: dizer que nunca ajuda seria excessivo..

Com treino, os pesos cosseno continuam ajudando pouco



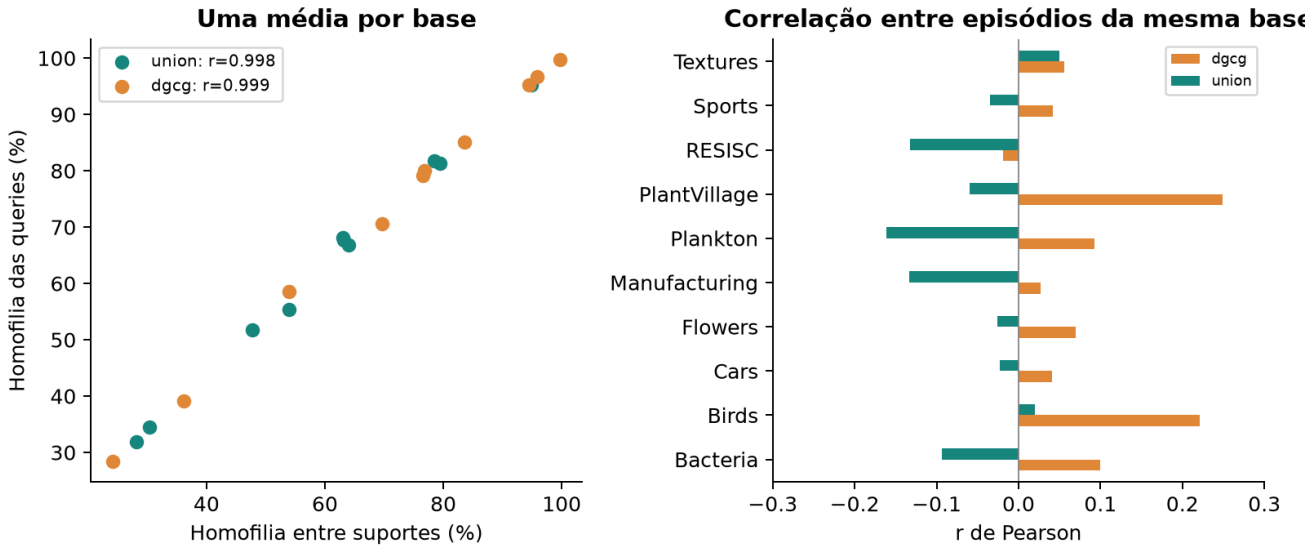
Como ler: compare RBF cosseno treinado ao mesmo grafo treinado sem esse peso.. São 40 execuções, não apenas o recorte parcial inicial do README..

No 1-shot, o ganho médio é +0,09 pp no union e +0,40 pp no DGCG, com melhora em 6/10 e 4/10 bases.. No 5-shot, os ganhos sobem para +0,94 e +0,67 pp, com 7/10 bases melhores em ambos.. A distribuição por base importa: ganho médio positivo não equivale a melhora universal..

A média final 5-shot é 75,78% no union e 75,81% no DGCG.. Essas condições ainda não superam a média 76,10% do no-graph sem treino.. Isso sugere benefício incremental dos pesos, sem sustentar que resolvem o problema geral..

RBO² treinado e DGCG+ treinado não foram executados.. Não há conclusão sobre eles nesta bateria..

O proxy é excelente entre bases e fraco por episódio

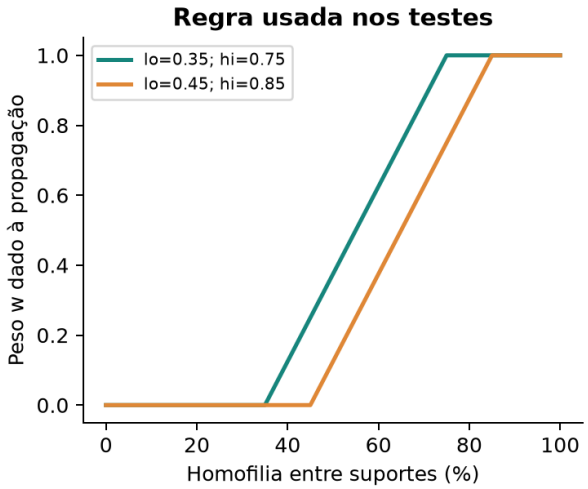


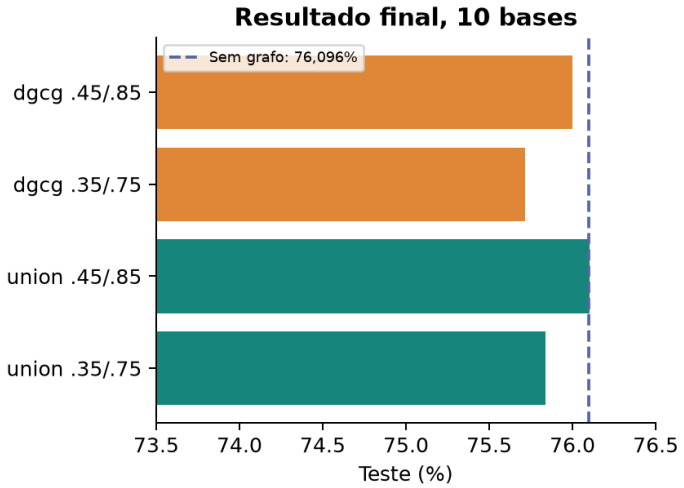
À esquerda: uma média por base.. Bases com suportes bem conectados também têm queries bem conectadas: r≈0,998 no union e 0,999 no DGCG.. À direita: a correlação entre os episódios de cada base, já calculada nos arquivos.. Sua média é −0,059 no union e 0,088 no DGCG.. São 150 episódios por base/método neste diagnóstico..

Analogia: saber que uma cidade é mais quente que outra não garante prever a temperatura de cada hora do dia.. Aqui, o proxy identifica características gerais das bases, mas quase não acompanha a variação de qualidade entre episódios da mesma base..

Consequência: ainda não temos evidência forte de que a regra identifica precisamente quando cada episódio merece mais propagação.. Ela pode estar funcionando principalmente como uma redução média da intensidade do grafo.. Isso deve ser comparado a um peso fixo calibrado na validação e a pesos embaralhados entre episódios da mesma base..

O adaptativo recuperou o dano — e chegou ao empate





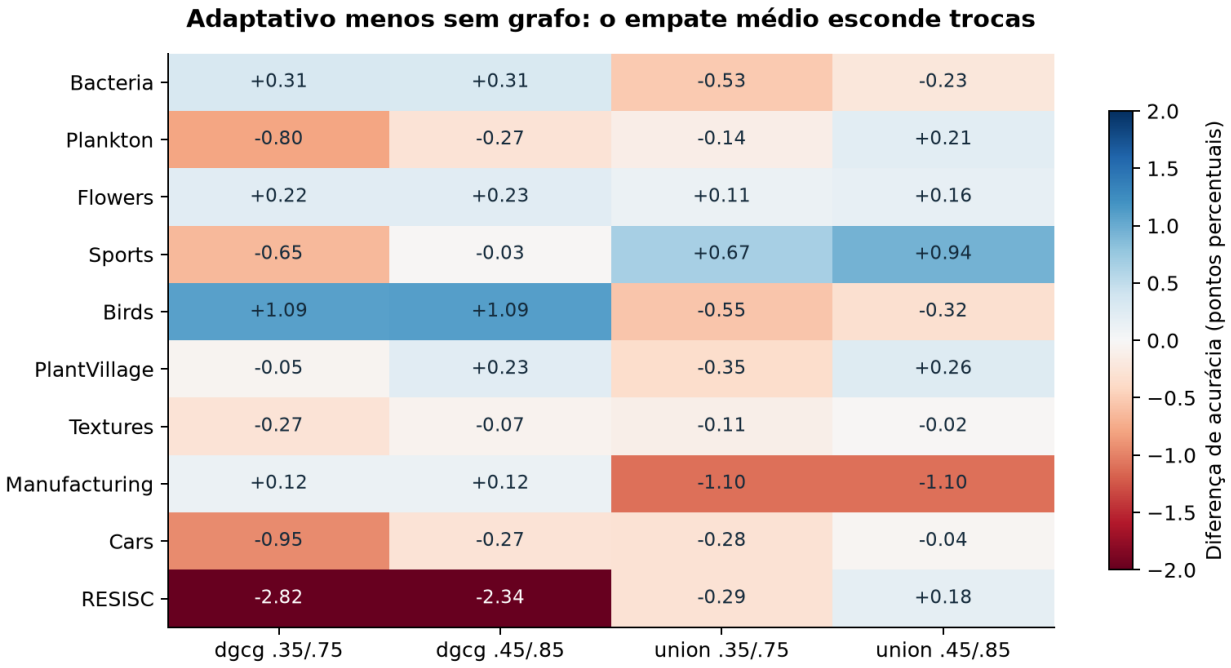
A regra calcula a homofilia entre suportes do episódio: h.. Depois usa w = clip((h−lo)/(hi−lo), 0, 1) e mistura wÂ + (1−w)I antes dos saltos.. h baixo reduz propagação; h alto a mantém.. Só usa rótulos dos suportes, disponíveis no problema..

O union original tinha 73,45%.. Os dois limiares chegam a 75,84 e 76,10%.. O DGCG sai de 73,84% para 75,72 e 76,00%.. O controle sem grafo é 76,0964%; union com 0,45/0,85 dá 76,1018%, diferença de apenas +0,0054 pp.. Arredondar e chamar isso de vitória seria enganoso..

Os dois pares de limiares foram definidos a priori segundo o registro do experimento, não selecionados pela validação.. Mostramos os dois; escolher agora o melhor pelo teste introduziria viés.. O resultado sustenta recuperação, mas não superioridade..

1-shot: não há dois suportes da mesma classe.. Esse proxy não mede conexões positivas; o código volta a w=1.. A regra precisa de outro sinal para atuar nesse regime..

O empate médio também esconde quem ganha e perde



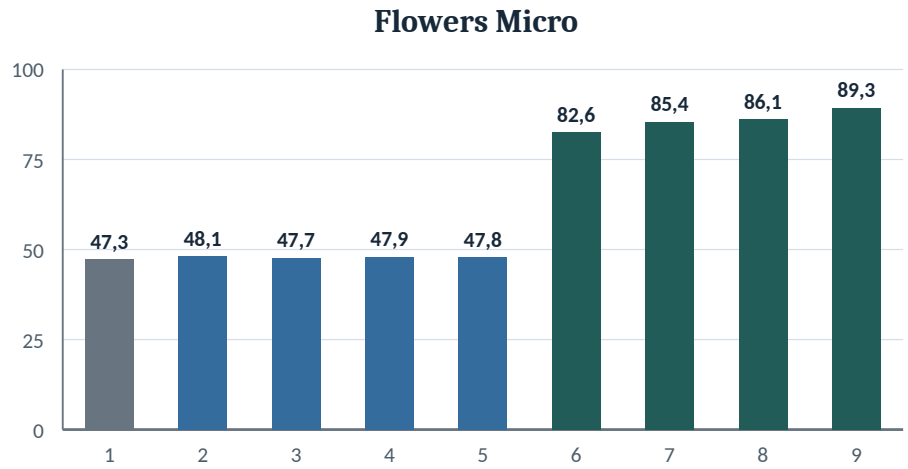
Como ler: cada célula compara a regra adaptativa com no-graph sem treino na mesma base.. Assim, o gráfico responde à pergunta de pesquisa mais exigente: usar o grafo acrescentou valor ao baseline forte?

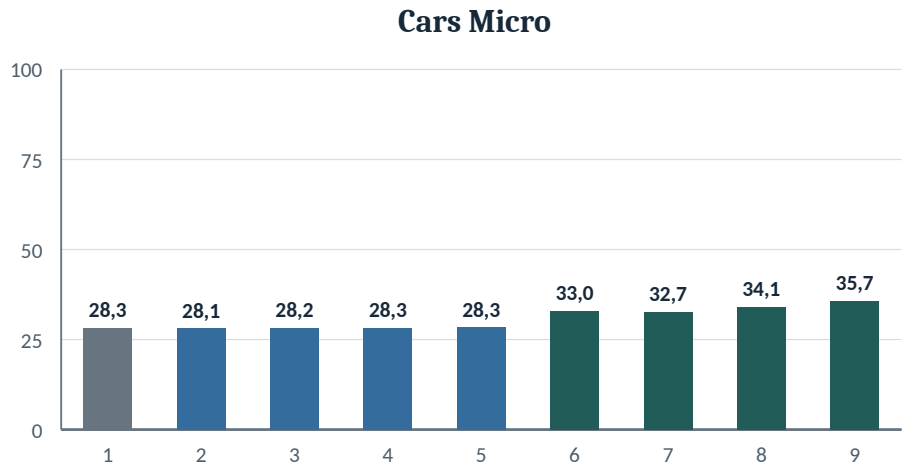
Union 0,45/0,85 ganha em 5/10 bases.. Sports ganha 0,94 pp, Manufacturing perde 1,10 pp; várias outras diferenças ficam perto de zero.. Não há vitória generalizada, e uma seed não permite tratar diferenças pequenas como estáveis..

Não confundir melhora relativa: ganhar aproximadamente 2,65 pp sobre um grafo prejudicial é útil para controle de dano.. Para defender um método novo, falta mostrar que ele adiciona informação além de preservar a representação original.. Uma regra fixa simples pode conseguir resultado semelhante: esse controle ainda falta..

Contexto de queries

Flowers e Cars Micro. A query avaliada e o suporte são os mesmos no controle e nas condições com contexto.





Acurácia de teste (%) por condição. Médias das seeds 7, 17 e 27.

Nº	Fase	Contextos no episódio	Flowers (%)	Ganho (pp)	Cars (%)	Ganho (pp)
1	Controle	0	47,27	+0,00	28,27	+0,00
2	Treino	25	48,08	+0,81	28,09	-0,17
3	Treino	45	47,71	+0,44	28,23	-0,03
4	Treino + validação	25	47,95	+0,67	28,29	+0,03
5	Treino + validação	45	47,77	+0,50	28,34	+0,07
6	Somente teste	25	82,57	+35,30	32,99	+4,73
7	Somente teste	45	85,38	+38,11	32,69	+4,43
8	Todas as fases	25	86,13	+38,86	34,09	+5,83
9	Todas as fases	45	89,27	+41,99	35,72	+7,45

O ganho maior aparece com o contexto disponível no teste. O protocolo usa kNN-union, 5-way, 1-shot e uma query avaliada por classe. As imagens de contexto entram no grafo com os rótulos ocultos.

Planilha por bateria, aba 15 Contexto de queries. Fonte por seed em resultado_contexto_query.csv (54 execuções).

Comparação de features | Flowers Micro

ResNet-18 a 128 px e ViT-B/16 a 224 px, ambos congelados e com pesos ImageNet. Médias das seeds 7, 17 e 27.

5-way · 1-shot · 10 queries por classe

Método	ResNet sem treino	ViT sem treino	ResNet com treino	ViT com treino
Sem grafo	80,41%	77,58%	79,81%	75,04%
kNN-union	90,14%	89,95%	89,66%	87,33%
DGCG densidade global	89,07%	89,62%	90,05%	87,48%
DGCG 4-6	88,08%	87,67%	88,79%	84,89%
DGCG 2-4	85,45%	84,39%	85,01%	82,33%

5-way · 5-shot · 10 queries por classe

Método	ResNet sem treino	ViT sem treino	ResNet com treino	ViT com treino
Sem grafo	95,09%	95,06%	92,73%	90,49%
kNN-union	94,61%	95,05%	94,09%	92,72%
DGCG densidade global	95,26%	95,89%	94,34%	91,90%
DGCG 4-6	95,22%	95,98%	94,49%	91,97%
DGCG 2-4	95,20%	95,86%	93,50%	90,94%

Maior média por cenário

1-shot: ResNet sem treino com kNN-union (90,14%). 5-shot: ViT sem treino com DGCG 4-6 (95,98%).

Planilha por bateria, aba 16 Comparação de features. A bateria tem 240 condições ao todo, com 44 reaproveitadas e 196 novas. As médias e desvios entre seeds estão em medias_features.csv.

Comparação de features | Cars Micro

ResNet-18 a 128 px e ViT-B/16 a 224 px, ambos congelados e com pesos ImageNet. Médias das seeds 7, 17 e 27.

5-way · 1-shot · 10 queries por classe

Método	ResNet sem treino	ViT sem treino	ResNet com treino	ViT com treino
Sem grafo	33,66%	63,98%	37,42%	56,81%
kNN-union	31,93%	68,94%	35,01%	67,74%
DGCG densidade global	31,47%	66,24%	35,10%	65,36%
DGCG 4-6	31,50%	66,86%	34,26%	66,04%
DGCG 2-4	31,48%	65,66%	34,40%	63,66%

5-way · 5-shot · 10 queries por classe

Método	ResNet sem treino	ViT sem treino	ResNet com treino	ViT com treino
Sem grafo	50,03%	77,45%	48,57%	71,65%
kNN-union	41,51%	75,88%	45,95%	75,51%
DGCG densidade global	45,90%	76,23%	46,27%	71,26%
DGCG 4-6	43,61%	75,60%	46,51%	74,45%
DGCG 2-4	44,96%	76,11%	46,84%	72,58%

Maior média por cenário

1-shot: ViT sem treino com kNN-union (68,94%). 5-shot: ViT sem treino e sem grafo (77,45%).

Planilha por bateria, aba 16 Comparação de features. A bateria tem 240 condições ao todo, com 44 reaproveitadas e 196 novas. As médias e desvios entre seeds estão em medias_features.csv.

Experimentos exploratórios anteriores

Estes resultados vieram de protocolos ou fontes diferentes dos 60 treinos da VM. Cada linha mantém seu próprio controle.

Experimento	Comparação	Resultado de teste
Ajuste piloto do DGCG	5-way, 1-shot, 5 queries por classe. Densidade 0,125 escolhida pela validação. Nove bases completas nessa varredura. PlantVillage ficou incompleta.	DGCG 4-6 62,35%. Densidade 0,125 62,64%. Escolha por base e transferência para base separada ficaram ambas em -0,02 pp.
Rankings globais no teste	Flowers. Mesmo checkpoint em 1.000 episódios 5-way, 1-shot, 5-query. O ranking global usa 200 imagens da partição de teste sem rótulos.	Ranking do episódio 83,43%. Ranking global 89,26% (+5,83 pp).
Piloto de imagens extras	2-way, 10-shot, 10-query. Dez bases, seed 7. Foram 470 execuções com controle e fases isoladas, incluindo validação e teste.	kNN-union com 10 extras por classe na propagação em todas as fases fez 90,83%. O controle sem grafo fez 90,80%.
Homofilia com treino em CPU	Reanálise da acurácia treinada histórica das dez bases. Homofilia das queries medida em separado com os vetores congelados.	Pearson entre homofilia e ganho sobre o sem grafo de 0,69 em 1-shot e 0,76 em 5-shot. A bateria da VM com curvas está nas páginas 14-19.

O piloto de ajuste da densidade usa cinco queries por classe. A varredura do relatório principal reúne 27 protocolos. O teste com ranking global usa imagens de referência de toda a partição de teste e mede uma forma diferente de contexto transdutivo.

Fontes nos Anexos do PDF, dentro de dados_complementares.zip. Consulte as pastas ajuste_piloto, rankings_globais, extras_piloto e homofilia_cpu.